

Báo cáo giữa kỳ Nhập môn học máy: Relation Graph Transformer



Nhóm FHD, AI23@HCMUS

Sinh viên thực hiện:

Nguyễn Đình Hà Dương - 23122002

Bùi Duy Bảo - 23122021

Nguyễn Việt Hùng - 23122032

Giáo viên hướng dẫn:

TS.

—
FIT@HCMUS, VNUHCM

Ngày 24 tháng 4 năm 2026



HCMUS
Viet Nam National University
Ho Chi Minh City
University of Science

fit@hcmus

I. Giới thiệu

RelGT (Relation Graph Transformer)

I.1. Giới thiệu

Nguồn gốc: arXiv:2505.10960v1 [cs.LG], 16 tháng 5 năm 2025

Tác giả: Vijay Prakash Dwivedi, Sri Jaladi, Yangyi Shen, Federico López, Charilaos I. Kanatsoulis, Rishi Puri, Matthias Fey, Jure Leskovec.

RELGT là kiến trúc Graph Transformer đầu tiên được thiết kế đặc biệt cho dữ liệu bảng quan hệ đa bảng. Mô hình vượt trội GNN cơ sở lên đến **18%** trên 21 tác vụ trong chuẩn đánh giá RelBench bằng chiến lược token hóa 5 thành phần và cơ chế chú ý cục bộ-toàn cục.

I.2. Bối cảnh Relational Deep Learning

Bài toán thực tế

Trong hầu hết hệ thống doanh nghiệp (TMĐT, tài chính, y tế, viễn thông), dữ liệu không nằm trong một bảng duy nhất mà phân tán theo nhiều bảng quan hệ, nhiều loại thực thể và nhiều mốc thời gian.

- Mỗi bảng có miền giá trị và vai trò nghiệp vụ khác nhau.
- Quan hệ không ngẫu nhiên mà bị ràng buộc bởi khóa chính/khóa ngoại.
- Nhiều tác vụ dự báo cần tuân thủ trục thời gian để tránh rò rỉ dữ liệu tương lai.

Hàm ý mô hình hóa

Mô hình tốt phải hiểu được đồng thời: **ngữ nghĩa bảng**, **liên kết quan hệ**, và **động lực thời gian** trong cùng một không gian biểu diễn.

I.3.Hạn chế của GNN truyền thống

Biểu đạt

- Trường nhìn theo số hop
- Over-squashing
- Tương tác xa khó truyền

Hệ thống

- Khó mở rộng theo schema lớn
- Chưa mạnh ở temporal-causal
- Thiếu cơ chế toàn cục

Diễn giải trực quan

Trong bài toán quan hệ nhiều bảng, tín hiệu quan trọng thường nằm xa seed node. Khi chỉ truyền theo cạnh cục bộ, tín hiệu này bị suy giảm hoặc “nén quá mức”, làm mô hình bỏ lỡ phụ thuộc xa có giá trị.

I.4.RELGT:Cơ sở dữ liệu quan hệ

Definition (Cơ sở dữ liệu quan hệ)

Một CSDL quan hệ là bộ $(\mathcal{T}, \mathcal{R})$:

- $\mathcal{T} = \{T_1, \dots, T_n\}$: tập các bảng
- $\mathcal{R} \subseteq \mathcal{T} \times \mathcal{T}$: quan hệ (FK-PK)

Mỗi thực thể gồm:

- Khóa chính (Primary Key)
- Khóa ngoại (Foreign Key)
- Thuộc tính đặc trưng
- Nhãn thời gian

I.5. Relational Entity Graph (REG)

Definition (Relational Entity Graph)

$$\mathcal{G} = (\mathcal{V}, \mathcal{E}, \varphi, \psi, \tau)$$

■ $\mathcal{V}$: tập nút (thực thể)

■ $\mathcal{E}$: tập cạnh (quan hệ)

■ $\varphi : \mathcal{V} \rightarrow \mathcal{T}$: kiểu nút

■ $\psi : \mathcal{E} \rightarrow \mathcal{R}$: kiểu cạnh

■ $\tau : \mathcal{V} \rightarrow \mathbb{R}$: thời gian

Ý nghĩa

REG chuyển dữ liệu quan hệ thành đồ thị để mô hình học: Cấu trúc (ai nối với ai), Ngữ nghĩa (nối theo kiểu gì), Thời gian (xảy ra khi nào).

I.6. Ba đóng góp trọng tâm của ReiGT

1. **Token hóa 5 thành phần** để biểu diễn mỗi node theo nhiều chiều thông tin thay vì một vector gộp đơn giản.
2. **Transformer 2 nhánh** kết hợp nhận thức cục bộ (local) và tri thức xa (global centroid).
3. **Hiệu năng mạnh trên RelBench** cho thấy thiết kế này có giá trị thực nghiệm, không chỉ mang tính ý tưởng.


Ý tưởng cốt lõi

Dùng attention để tăng biểu đạt xa nhưng vẫn giữ pipeline huấn luyện có thể mở rộng.

Điểm quan trọng

RELGT không phủ nhận GNN, mà kế thừa ưu điểm lấy mẫu theo neighborhood rồi nâng cấp năng lực biểu đạt bằng tokenization + transformer.

I.7. Pipeline tổng thể



- Luồng xử lý tách bạch giúp dễ kiểm thử: lỗi ở sampling, token hóa hay attention đều có thể truy vết.
- Cấu trúc pipeline này cũng thuận tiện cho precompute và huấn luyện phân tán.

I.8 RelGT: Temporal 2-hop sampling

$$\mathcal{N}(v_i) = \{v_j : d(v_i, v_j) \leq 2, \tau(v_j) \leq \tau(v_i)\}$$

- Giữ tính nhân quả bằng ràng buộc thời gian.
- Nếu thiếu neighbor thì sample có lặp hoặc fallback global.

Vì sao bước này quan trọng?

Nếu không kiểm soát thời gian ở giai đoạn lấy mẫu, mô hình có thể “nhìn thấy tương lai” và đạt điểm đánh giá ảo. RELGT xử lý vấn đề này ngay từ đầu pipeline.

Hệ quả thực tế

Mặc dù có thể làm khó huấn luyện hơn (ít neighbor hợp lệ hơn), kết quả thu được đáng tin cậy hơn khi triển khai thật.

I.8 RelGT: Token hóa 5 thành phần

$$t(v_j|v_i) = (x_{v_j}, \varphi(v_j), p(v_i, v_j), \tau(v_j) - \tau(v_i), \text{GNN-PE}_{v_j})$$
$$h_{\text{token}} = O[h_{\text{feat}} || h_{\text{type}} || h_{\text{hop}} || h_{\text{time}} || h_{\text{pe}}]$$

- Mỗi thành phần có encoder riêng để tránh “trộn mất ngữ nghĩa” quá sớm.
- Hợp nhất thành token embedding cho transformer ở tầng sau.

Phân tích ngôn từ

Đây là điểm khác biệt lớn so với nhiều baseline: thay vì ép mọi thông tin vào một vector thô, RELGT giữ cấu trúc thông tin đến sát tầng attention, giúp mô hình quyết định “nên chú ý vào loại thông tin nào”.

I.8 RelGT Local + Global module

$$h_{\text{local}}(v_i) = \text{Pool} \left(\text{EncoderLayer}^L(\{h_j\}_{j=1}^K) \right)$$

$$h_{\text{global}}(v_i) = \text{Attn}(q(v_i), K_{\text{cb}}, V_{\text{cb}}), \quad c_{v_i} = \arg \min_{b \in [B]} \|q_{v_i} - e_b\|_2$$

$$h(v_i) = \text{MLP}([h_{\text{local}} \| h_{\text{global}}])$$

- **Local branch:** mạnh ở chi tiết lân cận và mẫu tương tác ngắn.
- **Global branch:** bổ sung tri thức xa thông qua codebook centroid.

Ý nghĩa mô hình

Hai nhánh đóng vai trò bổ sung: local chống mất chi tiết, global chống “cận thị cấu trúc”.

I.9. Kết quả thực nghiệm tiêu biểu

Task	RDL	HGT	RelGT
rel-f1 / driver-top3 (AUC)	0.7554	0.7075	0.8352
rel-f1 / driver-dnf (AUC)	0.7262	0.7077	0.7587
rel-stack / user-engagement (AUC)	0.9021	0.8847	0.9053
rel-f1 / driver-position (MAE)	4.022	4.2263	3.9170
rel-avito / ad-ctr (MAE)	0.0410	0.0462	0.0345
rel-event / user-attendance (MAE)	0.2580	0.2635	0.2502

Diễn giải kết quả

Bảng điểm cho thấy RELGT cải thiện nhất quán trên cả phân loại và hồi quy. Điều này gợi ý rằng kiến trúc không chỉ tối ưu cho một metric cụ thể mà có khả năng tổng quát tốt trên nhiều kiểu tác vụ.

I.10. Phân tích điểm mạnh cốt lõi của RELGT

Điểm mạnh về mặt mô hình hóa

RELGT đưa bài toán quan hệ từ góc nhìn message passing thuần sang góc nhìn token-attention có cấu trúc, nhờ đó mô hình quyết định linh hoạt hơn: **thông tin nào quan trọng, ở đâu, và ở thời điểm nào.**

- **Tính mô-đun cao:** sampling, tokenization, local/global attention tách lớp rõ ràng.
- **Tính diễn giải tốt hơn:** có thể theo dõi đóng góp theo nhóm token và theo nhánh local-global.
- **Tính công nghiệp:** phù hợp precompute, batching lớn, và huấn luyện DDP.

Nhận định

Giá trị lớn của RELGT nằm ở chỗ cân bằng được hai mục tiêu thường xung đột: **biểu đạt mạnh** và **khả năng mở rộng triển khai.**

I.11 Giới hạn còn lại và phát triển

Các giới hạn còn tồn tại trong RELGT gốc

Dù đạt kết quả mạnh, RELGT vẫn có các điểm có thể gây trần hiệu năng khi mở rộng quy mô hoặc khi dữ liệu lệch phân phối.

- **Fusion còn tĩnh:** concat tuyến tính chưa tái cân bằng đa modality theo từng mẫu.
- **Codebook dễ lệch:** cơ chế EMA giúp ổn định nhưng chưa đủ mạnh trong mọi phân bố dữ liệu.
- **Readout một góc nhìn:** có thể bỏ sót tín hiệu hiếm hoặc tương tác khó.
- **Tương tác local-global:** còn thiên về ghép nối hơn là trao đổi ngữ nghĩa hai chiều.

Cầu nối logic

Chính các giới hạn này là lý do trực tiếp dẫn tới thiết kế RelGT++: fusion động, codebook mềm có regularization, readout đa góc nhìn, và cầu nối attention hai chiều.

II. Phát triển

RelGT ++ (Relation Graph Transformer plus plus)

II.1.RELGT++: Động lực nâng cấp

Vấn đề cốt lõi quan sát từ RelGT

RelGT đã mạnh ở mức kiến trúc nền, nhưng còn ba điểm gây trần hiệu năng: hợp nhất token còn tĩnh, codebook toàn cục thiếu cơ chế tự ổn định mạnh, và nhánh local-global chưa tương tác đủ sâu.

- **Mức biểu diễn:** thông tin đa modal chưa được tái cân bằng theo từng mẫu.
- **Mức tối ưu:** codebook dễ lệch phân bố khi dữ liệu không đồng đều.
- **Mức suy luận:** readout một góc nhìn dễ bỏ sót tín hiệu hiếm.

Hướng nâng cấp

RelGT++ đưa 6 module để xử lý trực tiếp từng điểm nghẽn: CrossModalGatedFusion, GumbelSoftCodebook, CrossAttentionBridge, MultiViewReadout, SwiGLU FFN, Stochastic Depth.

II.2.RELGT++: CrossModalGatedFusion

$$\text{ctx}_i = \frac{1}{N-1} \sum_{j \neq i} e_j, \quad g_i = \sigma(W_{\text{self}}^i e_i + W_{\text{ctx}}^i \text{ctx}_i)$$
$$h_{\text{fused}} = \text{LN} \left(W_{\text{out}} \sum_{i=1}^N g_i \odot W_{\text{val}}^i e_i \right)$$

Phân tích cơ chế

Thay vì coi 5 nguồn thông tin là ngang nhau như concat, gate học được mức quan trọng của từng modality theo **ngữ cảnh mẫu hiện tại**. Vì vậy, một node có tín hiệu thời gian mạnh có thể tự động tăng trọng số temporal và giảm các kênh yếu.

- **Lợi ích:** tăng tính thích nghi theo từng task và từng mini-batch.
- **Rủi ro:** nếu gate bão hòa quá sớm, có thể xuất hiện dead modality.

II.3.RELGT++: GumbelSoftCodebook + entropy

$$z_{ik} = \frac{-\|x_i - e_k\|_2^2 + \text{Gumbel}_{ik}}{\tau}, \quad p_k = \text{softmax}(z_{ik})$$

$$\mathcal{L}_{\text{entropy}} = 1 - \frac{H(\hat{p})}{\log B}, \quad H(\hat{p}) = - \sum_{b=1}^B \hat{p}_b \log \hat{p}_b$$

Phân tích động lực học

Gumbel-Softmax làm assignment mềm trong giai đoạn đầu để khám phá, sau đó annealing nhiệt độ giúp hội tụ cụm sắc nét hơn. Cộng thêm entropy loss để tránh việc vài centroid bị dùng quá mức.

■ **Khác RelGT:** codebook không chỉ cập nhật theo EMA mà còn nhận gradient trực tiếp.

— **Ưu điểm:** tăng độ nhiễu codebook, giảm collapse

II.4.RELGT+: SwiGLU FFN và DropPath

$$\text{FFN}(x) = W_{\downarrow}(\text{SiLU}(W_g x) \odot W_{\uparrow} x)$$

$$\text{SD}(x; p) = \frac{x \cdot 1[\text{Bernoulli}(1 - p)]}{1 - p}$$

Phân tích theo tầng học biểu diễn

SwiGLU tăng khả năng chọn lọc đặc trưng ở FFN; DropPath buộc mạng học đường đi dự phòng qua residual, nhờ đó giảm phụ thuộc vào một nhánh duy nhất.

- **SwiGLU:** cải thiện độ mượt gradient khi mô hình sâu.
- **DropPath:** tăng tính tổng quát bằng regularization cấu trúc.
- **Hiệu ứng kết hợp:** ổn định train tốt hơn khi batch lớn.

II.5.RELGT++: MultiViewReadout và CrossAttentionBridge

$$\begin{aligned}h_{\text{local}} &= \text{LN}\left(h_i + \text{MLP}([v_{\text{attn}} \| v_{\text{mean}} \| v_{\text{max}}])\right) \\ \tilde{h}_l &= h_l + \alpha W_v^g h_g, \quad \tilde{h}_g = h_g + \beta W_v^l h_l \\ h_{\text{out}} &= \text{LN}(W_{\text{out}}(\gamma \odot \tilde{h}_l + (1 - \gamma) \odot \tilde{h}_g) + h_l)\end{aligned}$$

- **MultiViewReadout:** nhìn đồng thời theo trung bình, nổi bật cục bộ và trọng số attention.
- **CrossAttentionBridge:** local và global không còn ghép cơ học mà trao đổi thông tin hai chiều.

Hàm ý phân tích

Đây là bước chuyển từ “cộng đặc trưng” sang “hợp nhất ngữ nghĩa”, giúp giảm mù thông tin giữa hai nhánh.

II.6.RELGT++: Tổng kết phân tích RelGT++

- RelGT++ không chỉ thêm module mới mà thay đổi cách mô hình **ra quyết định biểu diễn**.
- Tác động mạnh nhất đến chất lượng thường đến từ fusion động và quản trị codebook.
- Biến số quyết định cuối cùng vẫn là độ chuẩn của training pipeline.

Kết luận phân tích

Nếu triển khai đúng, RelGT++ có cơ sở lý thuyết và kỹ thuật để vượt RelGT một cách ổn định hơn, không chỉ theo từng run đơn lẻ.

II.7. ReLGT++: Đánh giá theo ROC-AUC

Training Settings ReLGT và ReLGT++

Epochs=10, Batch=16, Channels=64, Neighbors=64, Centroids=256, Workers=0,
Steps/Epoch=50

So sánh mô hình:

■ Ref (Top 3 - F1):

- Val ROC-AUC: 0.730
- Test ROC-AUC: 0.766

■ ReLGT++:

- Val ROC-AUC: 0.714
- Test ROC-AUC: **0.800**

II.8. ReLGT++: Đánh giá theo ROC-AUC

Nhận xét

- Trên tập **validation**, ReLGT++ thấp hơn nhẹ so với baseline (0.714 vs 0.730).
- Trên tập **test**, ReLGT++ vượt trội rõ rệt (+0.034 ROC-AUC).
- Điều này cho thấy mô hình có **khả năng tổng quát hóa tốt hơn**. Trên một số bộ dữ liệu khác vẫn thua benchmark.

Ý nghĩa cải thiện

- ROC-AUC cao hơn $\rightarrow$ phân biệt tốt hơn. Ít phụ thuộc $\rightarrow$ ổn định hơn trong thực tế.
- Gợi ý rằng kiến trúc **ReLGT-X** học được cấu trúc quan hệ hiệu quả hơn và phải đánh giá kĩ càng hơn. Nhóm vẫn đang trong thời gian thử nghiệm

I. Hướng phát triển

RelGT_x(RelationGraphTransformer)

III.RELGT-X: Mục tiêu thiết kế


Bối cảnh xuất phát

Sau khi phân tích RelGT++, ta thấy mô hình đã mạnh hơn RelGT nhưng vẫn còn giới hạn về hiệu quả tính toán, ổn định theo thời gian và năng lực chuyển giao giữa task/lược đồ.

- Giảm chi phí all-pair local attention mà không hy sinh quá nhiều biểu đạt.
- Tách tín hiệu nhân quả và tương quan giả theo thời gian.
- Tăng tính bất biến schema và khả năng transfer đa task.

Mục tiêu: Efficiency + Causality + Generalization

III.RELGT-X: Kiến trúc tổng thể



Nguyên tắc thiết kế

RelGT-X không thay toàn bộ pipeline mà gắn module theo lớp: lớp tính toán (SGSA), lớp ngữ nghĩa quan hệ (RPE), lớp nhân quả thời gian (CTD), lớp bộ nhớ phân cấp (HCS), và lớp học bất biến (CSA/MLT).

III. RELGT-X: Attention theo cấu trúc quan hệ

SGSA (Schema-Guided Sparse Attention)

- Chỉ giữ lại các cặp attention **hợp lệ theo schema**
- Loại bỏ kết nối vô nghĩa → giảm nhiễu và chi phí tính toán.

RPE (Relational Positional Encoding)

- Bổ sung thông tin **đường đi quan hệ** giữa các node. Giải quyết hạn chế của hop distance (thiếu ngữ nghĩa)

Insight chính

SGSA giúp **lọc đúng kết nối**, RPE giúp **hiểu đúng ngữ nghĩa** ⇒ attention vừa **nhANH** hơn vừa **chính xác** hơn

FINAL-01: Tổng kết

Kết luận chính

- **RelGT**: nền tảng cho dữ liệu quan hệ đa bảng với token hóa và attention local-global.
- **RelGT++**: cải thiện khả năng biểu diễn, nhưng phụ thuộc vào pipeline huấn luyện.
- **RelGT-X**: mở rộng toàn diện: **hiệu quả + nhân quả + khả năng chuyển giao**.

Takeaway

RelGT → nền tảng, RelGT++ → hiệu năng, RelGT-X → triển khai bền vững.